hackathon
GENERATIVE A

TESSAN × SNOWFLAKE HACKATHON

THEO PIZZARDI
ALEXANDRE MEDOR
WIAM ESSADKI
ARIJ GHANNOUDI

https://github.com/Rose-X/hackathon-IA-2025/tree/main

UNIVERSITE PARIS 8 DES CRÉATIONS
université PARIS-SACLAY
UQAC Université du Québec à Chicoutimi

Analyse Acoustique Respiratoire par Intelligence Artificielle

1. Pertinence et Innovation

Contexte et enjeux identifiés

Les maladies respiratoires représentent la troisième cause de mortalité mondiale. En France, le diagnostic pulmonaire souffre de délais importants : un patient suspect d'asthme attend en moyenne 3 à 6 semaines avant de consulter un pneumologue. Les cabines médicales TESSAN capturent des sons pulmonaires lors de chaque consultation, sans pouvoir les analyser automatiquement — une ressource médicale précieuse inexploitée.

Réponse apportée par AW2A3-IA

AW2A3-IA est un système d'aide au diagnostic respiratoire qui transforme un enregistrement audio de 3 secondes en résultat indicatif en moins de 200 millisecondes. Il détecte 5 classes : Asthme, BPCO, Bronchique, Pneumonie et Sain. Chaque résultat est accompagné d'un indice de confiance et d'une recommandation médicale contextuelle, accessible directement depuis l'interface de la cabine.

Points clés d'innovation
Identification précise des besoins : détection de 5 pathologies depuis un enregistrement de 3 secondes, sans équipement spécialisé supplémentaire. **Innovation technique :** extraction de 137 features acoustiques (MFCC, Delta-MFCC, ZCR, Chroma) couplée à un Random Forest atteignant 89.6% d'accuracy sur 1 211 enregistrements réels. **Explainability médicale :** distribution complète des probabilités par pathologie et recommandation adaptée, compréhensible par le patient. **Architecture pensée pour Snowflake :** le pipeline est conçu pour une migration native vers Snowpark (non déployé dans le cadre de ce hackathon, mais documenté et prêt à l'intégration).
Interface médicale sobre : application desktop clinique et rassurante, conçue pour un usage en cabine par des patients non-experts.

La solution anticipe deux défis majeurs : la réticence des patients à confier leurs données à une IA, adressée par la transparence du score de confiance et le disclaimer médical systématique ; et la nécessité d'un résultat quasi-instantané lors d'une consultation courte, garantie par la latence inférieure à 200ms.

2. Qualité Technique et Faisabilité

Ce qui a été réellement implémenté

La solution a été développée et validée entièrement en local et vérifier pars un médecin nous avons utiliser Python, sans accès à un environnement Snowflake. Le pipeline complet est opérationnel : extraction des features audio, entraînement du modèle, évaluation et interface graphique fonctionnelle.

> Note de transparence : Snowflake n'a pas été utilisé dans ce projet. L'équipe n'avait pas accès à un compte Snowflake durant le hackathon.

Architecture locale implémentée

Script	Rôle
01_extract_features.py	Extraction MFCC (137 features)
02_train.py	Entraînement Random Forest
best_model.pkl	Modèle sauvegardé localement
03_evaluate.py	Métriques + courbes ROC
interface.py	Interface desktop tkinter

Performances mesurées en local

Métrique	Valeur
Accuracy globale (test set local)	**89.6%**
Latence d'inférence	**< 200ms**
Dataset utilisé	**1 211 fichiers .wav**
Meilleur modèle retenu	**Random Forest**

3. Impact, Risques et Responsabilité

Impacts positifs attendus

Si déployé en production, AW2A3-IA peut réduire significativement le délai de détection des pathologies respiratoires. Une détection précoce de la BPCO ou de la pneumonie peut éviter des hospitalisations coûteuses. Pour TESSAN, la solution augmente la valeur des cabines en ajoutant une couche d'analyse médicale automatique sur des données déjà collectées.

Risques identifiés
Risque 1 — Faux négatifs médicaux (critique)
Risque 2 — Dataset insuffisant (critique)
Risque 3 — Absence de déploiement Snowflake (Sécurité)
Risque 4 — Cadre réglementaire RGPD / dispositif médical

Limites clairement reconnues

- Snowflake non utilisé : la solution fonctionne uniquement en local.
- Dataset limité : 1 211 échantillons Kaggle — insuffisant pour une validation clinique formelle.
- Modèle Random Forest : performant sur ce dataset, mais moins puissant qu'une architecture CNN+BiLSTM.

4. Conclusion et Recommandations

Synthèse honnête des apports

AW2A3-IA démontre la faisabilité technique d'un système d'aide au diagnostic respiratoire basé sur l'acoustique. En conditions de hackathon, sans accès à Snowflake, l'équipe a produit un pipeline complet fonctionnel de l'extraction audio jusqu'à l'interface utilisateur médicale. A

Atteignant 89.6% d'accuracy sur données réelles.

Recommandations concrètes pour la suite

- **Immédiat :** obtenir un accès Snowflake Trial et valider la migration du pipeline.
- **Court terme :** enrichir le dataset avec des enregistrements TESSAN réels, viser 15 000 +(93-94% accuracy).
- **Moyen terme :** engager une validation clinique avec un partenaire médical *Pharmacie*. Déployer le pipeline Snowpark en production avec re-entraînement automatique mensuel.